MyMAI_Music Translation

딥러닝을 활용한 Singing Voice Conversion

김유민 박진혁 이소라 정혜인 조민호 최승호

00 Index

데이터 수집

WHAT we used?

Wav File Download from Melon

모델 구조

HOW does it work?

GAN / CycleGAN / CycleBEGAN

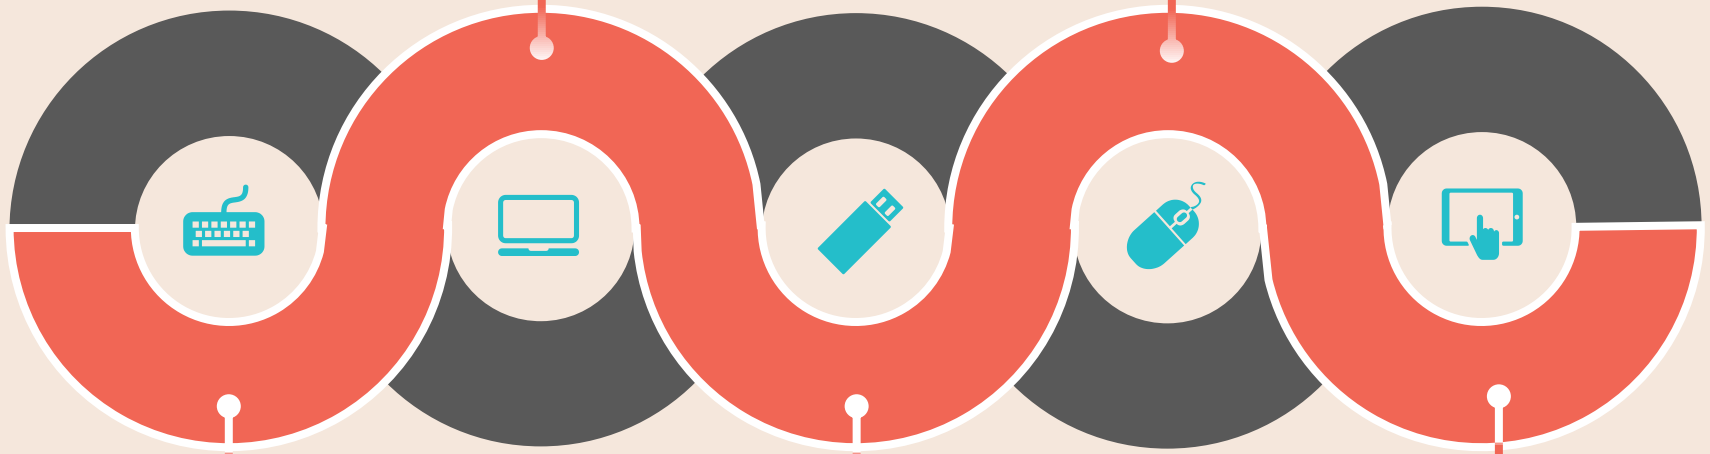

제안 배경

WHY Singing Voice Conversion?

듣고 싶은 노래를

내가 좋아하는 가수가 불러준다면

데이터 전처리

HOW we used?

Vocal Separation / Noise Reduction

/ Augmentation

결과 시연 및 개선 방향

Final Result & Discussion

결과 시연 / 한계점 / 개선 방향

01. Introduction

WHY Singing Voice Conversion?

01 제안 배경

Tacotron을 이용한 Voice Conversion

**TACO-VC: A SINGLE SPEAKER TACOTRON BASED VOICE CO
WITH LIMITED DATA**

Roee Levy-Leshem, Raja Giryes

School of Electrical Engineering, Tel Aviv University, Tel Aviv,

ABSTRACT

This paper introduces Taco-VC, a novel architecture for voice conversion (VC) based on the Tacotron synthesizer, which is a sequence-to-sequence with attention model. The training of multi-speaker voice conversion systems requires a large amount of

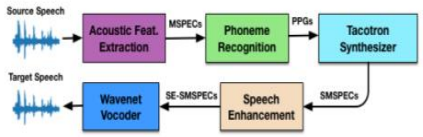

책 읽어주는 딥러닝 – 유인나 Ver.

제7회 투빅스 컨퍼런스 - 투빅스랩소디

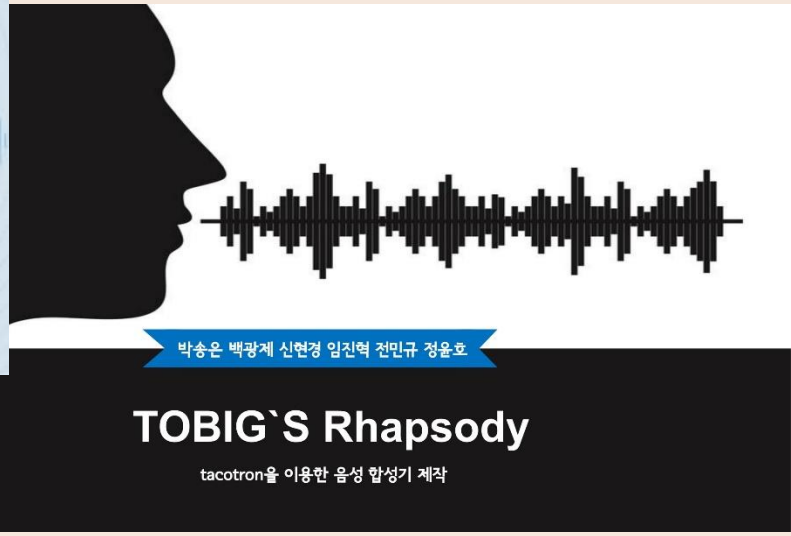

다양한 "Speech" Voice Conversion 시도들!

"Singing" Voice Conversion은.....?

01 제안 배경

Q. 내가 듣고 싶은 노래를

내가 좋아하는 가수가 불러준다면..?

거미 – You Are My Everything

with 아이유's voice

내가 듣고 싶은 노래를

내가 좋아하는 가수

케이윌 – 내 생에 아름다운

with 10cm's voice

02. DATA

WHAT we used?

Q. 우리는 어떤 데이터가 필요할까?

A. "목소리만 남은" 노래 데이터가 필요하다!

02 데이터 수집

-Original 가수-

-Conversion 가수-

각각 10곡 이상의 **원곡과 Inst.파일** 다운로드

ex) 아이유, 백지영, 거미, 신용재, 10cm, 케이윌 등

02 데이터 수집

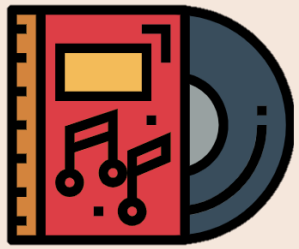

① 원곡 파일 & Inst.파일
각각 푸리에 변환

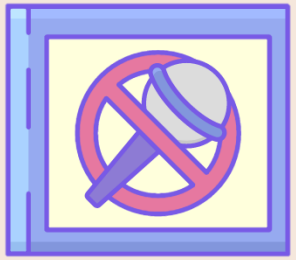

② 원곡과 Inst. 푸리에 변환값의
차이를 이용해 목소리 분리

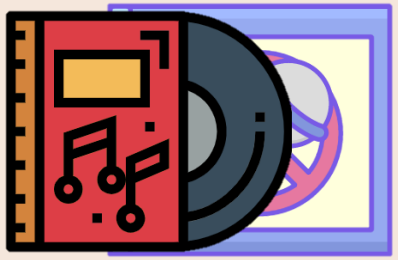

③ 목소리 분리 값 to .wav 파일
by 역푸리에 변환

cf. What is Fourier Transform?
시간에 대한 신호를
함수를 구성하고 있는 주파수 성분으로 분해하는 작업

03. Preprocessing

HOW we used?

03 데이터 전처리

1. Preprocessing

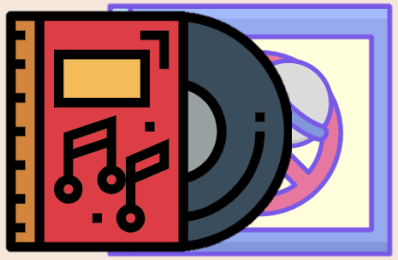

[목소리 분리 후 .wav 파일]

1) 무음값 제거

의미 있는 Feature만 뽑을 수 있도록 필요 없는 부분 제거

ex. 가사가 없는 부분, 간주 부분, 숨쉬는 부분 등

03 데이터 전처리

1. Preprocessing

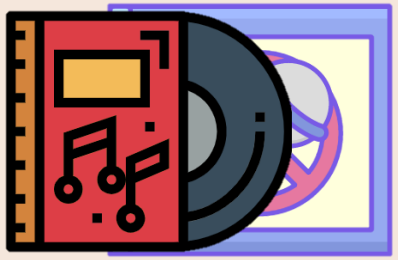

[목소리 분리 후 .wav 파일]

1) 무음값 제거

의미 있는 Feature만 뽑을 수 있도록 필요 없는 부분 제거

ex. 가사가 없는 부분, 간주 부분, 숨쉬는 부분 등

2) Notch Filter 적용

- 주파수 상에서 잡음으로 인식되는 Noise 제거
- 극도의 저주파와 고주파는 잡음과 동일함

→ 특정 범위를 벗어난 주파수는 잡음으로 인식

1. Preprocessing

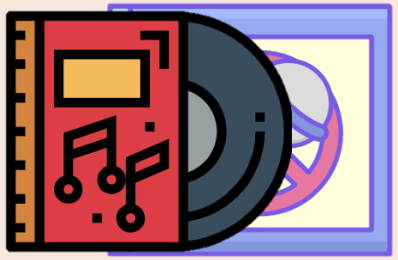

[목소리 분리 후 .wav 파일]

1) 무음값 제거
의미 있는 Feature만 뽑을 수 있도록 필요 없는 부분 제거
ex. 가사가 없는 부분, 간주 부분, 숨쉬는 부분 등

2) Notch Filter 적용
- 주파수 상에서 잡음으로 인식되는 Noise 제거
- 극도의 저주파와 고주파는 잡음과 동일함
→ 특정 범위를 벗어난 주파수는 잡음으로 인식

3) Noise Reduction
보다 세밀하게 곡 내에서의 잡음 인식 후 제거

03 데이터 전처리

케이윌 – 내 생에 아름다운
(원곡)

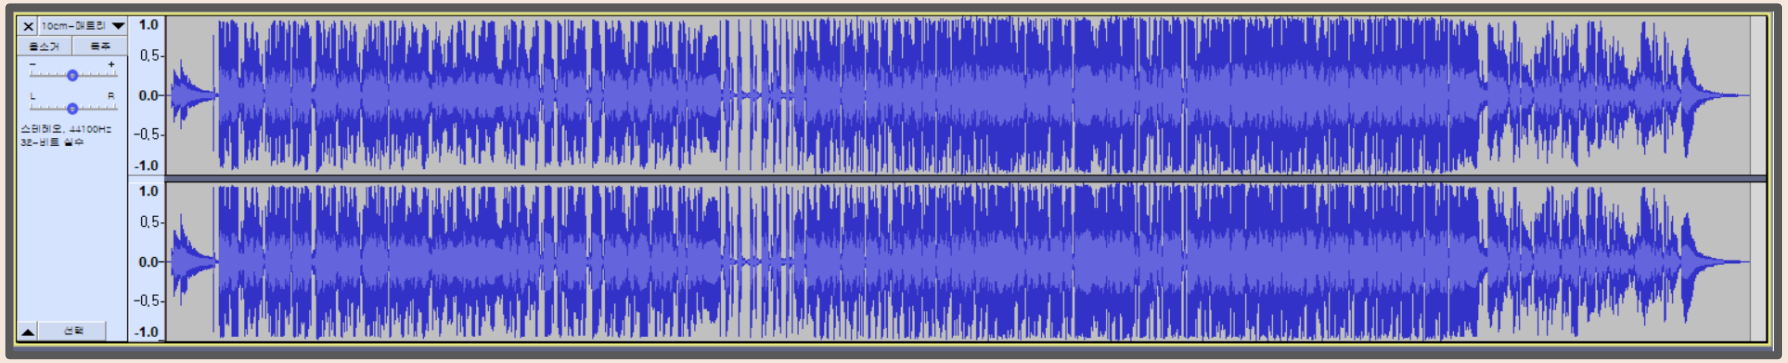

Before

케이윌 – 내 생에 아름다운
(전처리 후)

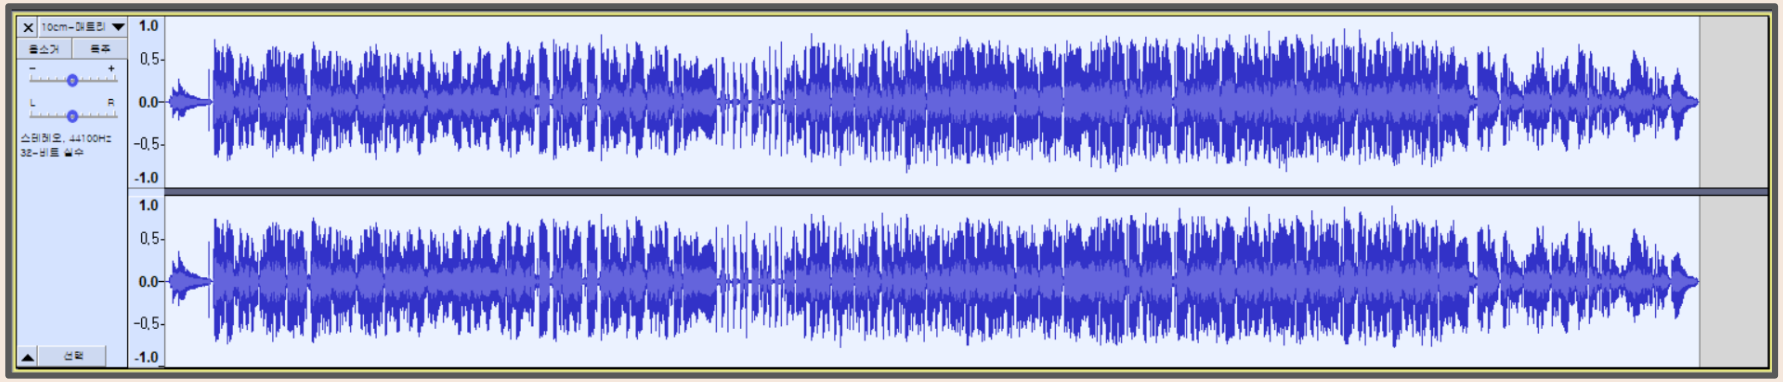

After

2. Augmentation

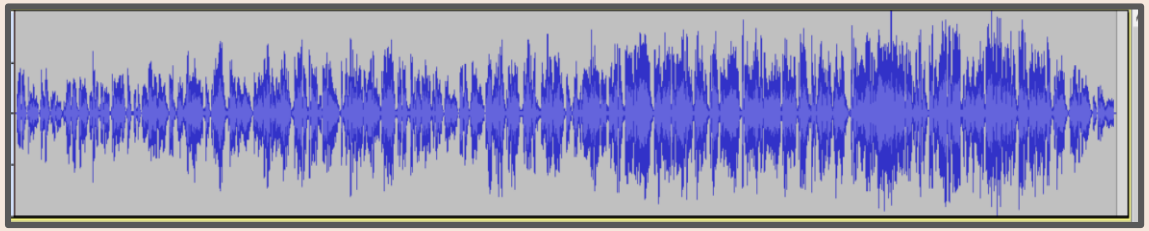

[원본]

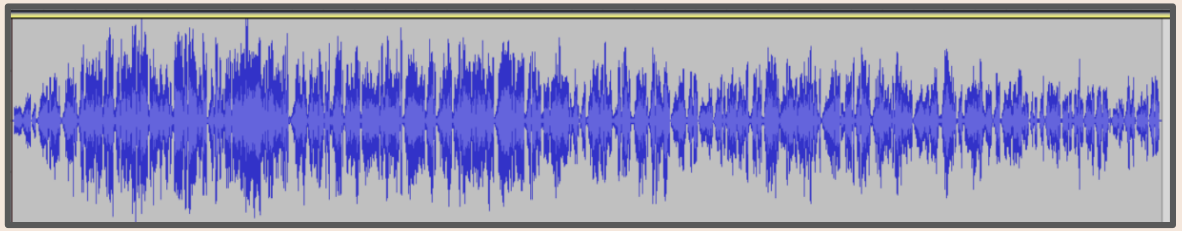

[거꾸로 재생]

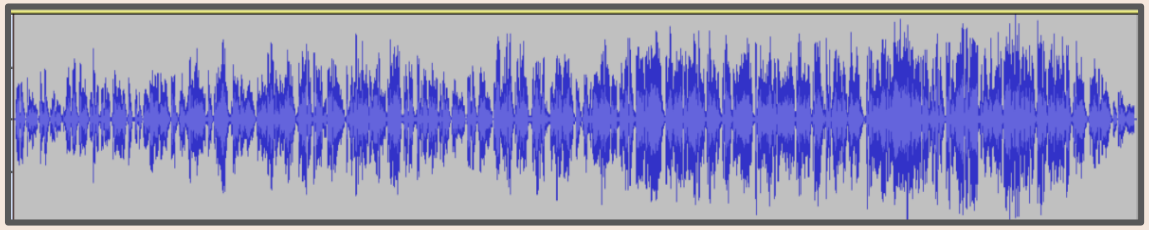

[위아래 뒤집기]

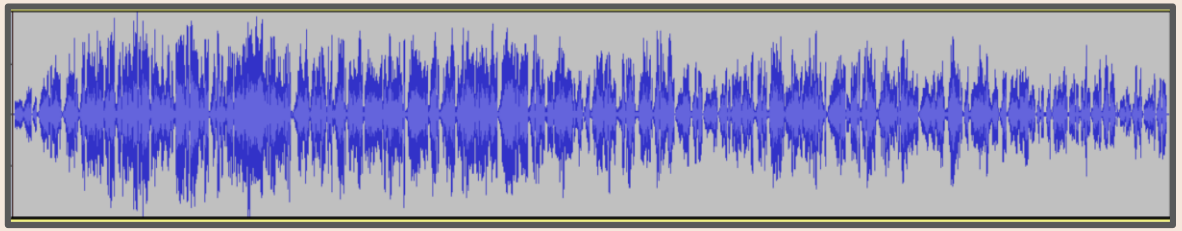

[거꾸로 재생 + 위아래 뒤집기]

2. Augmentation

[원본]

Augmentation을 통해
데이터 크기 4배 증강!

[거꾸로 재생]

White Noise, Stretch 등의 시도는
음정이 담긴 데이터라는 점에서 저하된 성능을 보임!

[위아래 뒤집기]

[거꾸로 재생 + 위아래 뒤집기]

04. MODEL

HOW we used?

04 모델 구조 - Feature Extraction

Model Input

[.wav 파일]

Feature Extraction
: MCEP

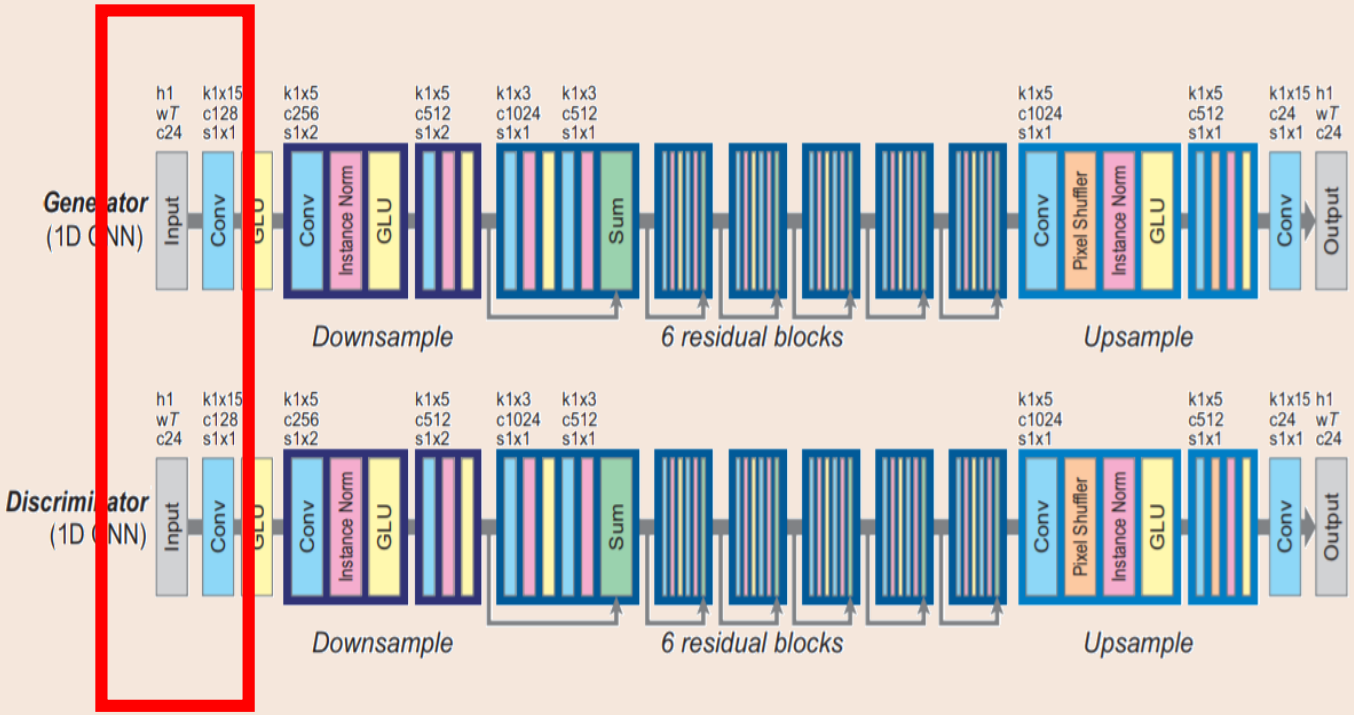

[Model]

04 모델 구조 - Feature Extraction

Audio Analysis

[Raw Wave]

① F0
- 근음(뿌리 근 소리 음)
- 소리를 들었을 때 사람이 인지하는 음의 뿌리가 되는 주파수

② Spectral Envelope
- Spectrum을 역푸리에 변환한 Cepstrum 중 저주파 부분

③ Aperiodicity Energy
- 주파수의 극소값과 극대값을 연결한 curve 간의 ratio
- Envelope 이외 진동하는 진폭의 정보

04 모델 구조 - Feature Extraction

Audio Analysis

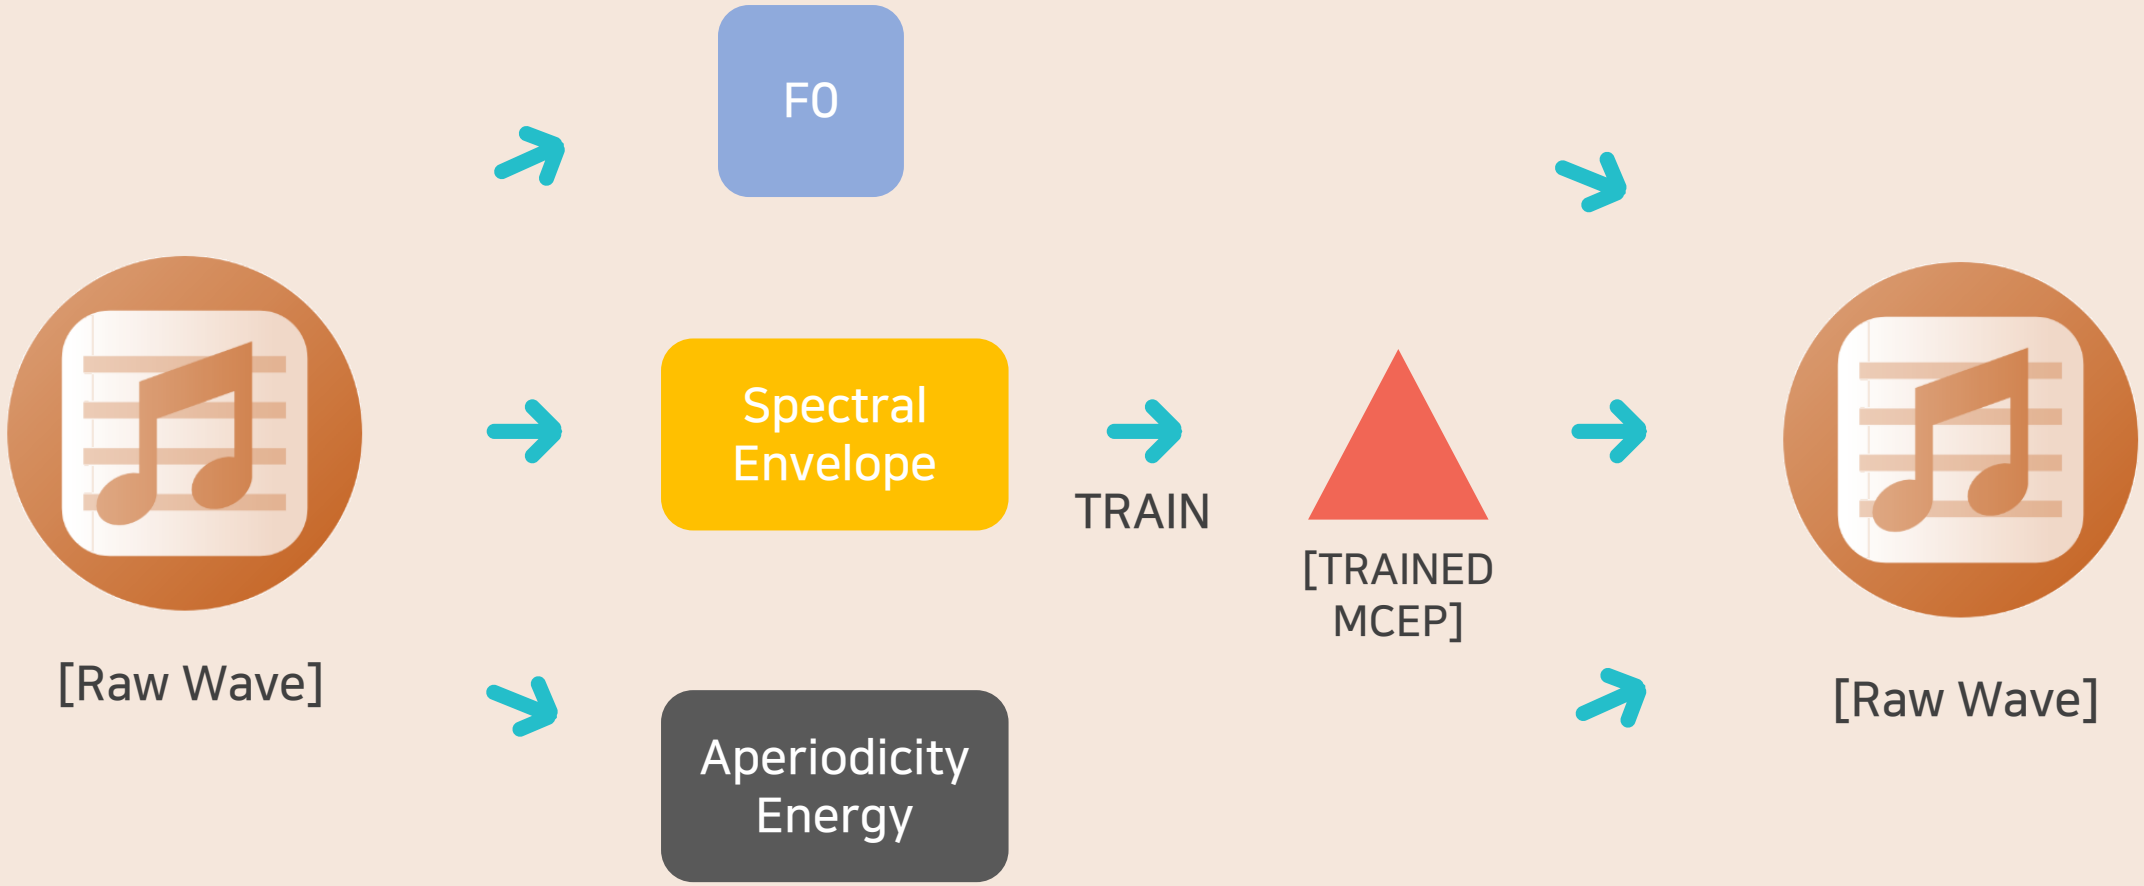

04 모델 구조 - Feature Extraction

Fourier Transform

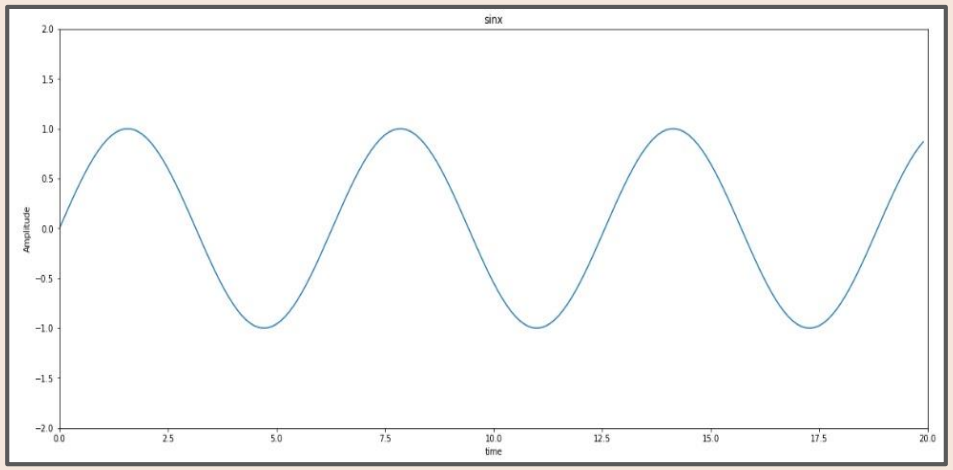

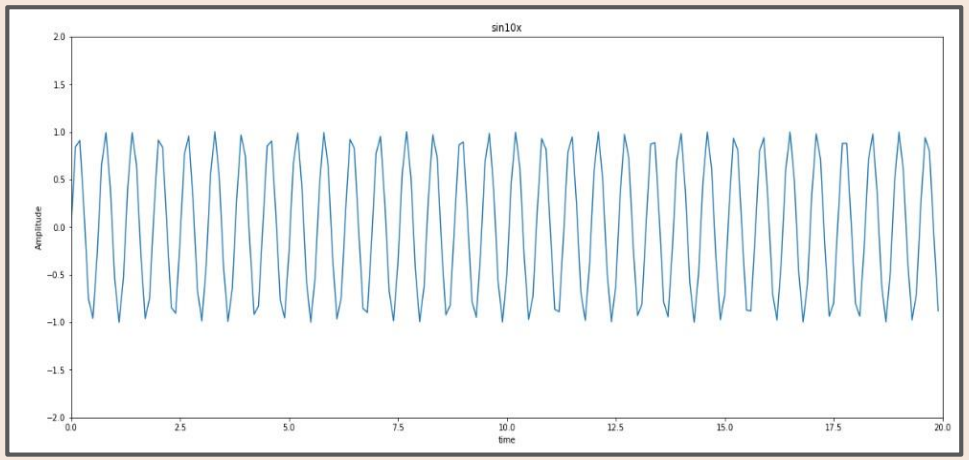

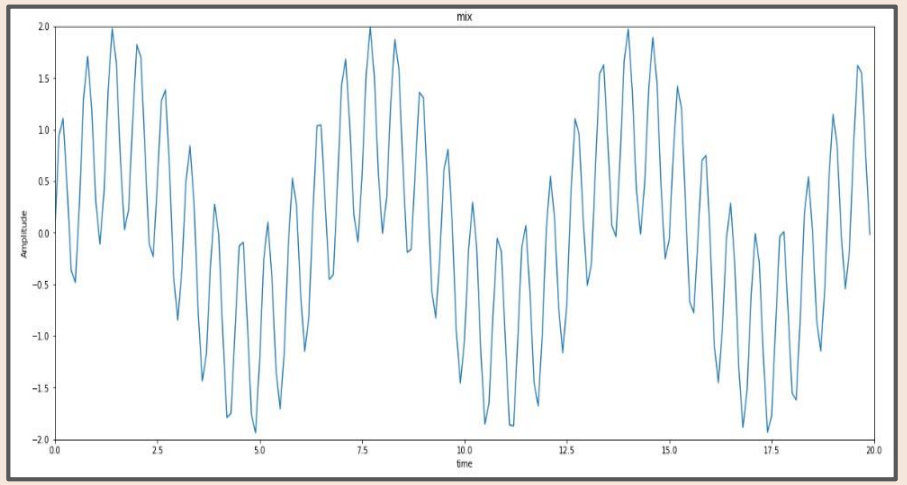

X축: Time(시간)
Y축: Amplitude(진폭)

04 모델 구조 - Feature Extraction

Fourier Transform

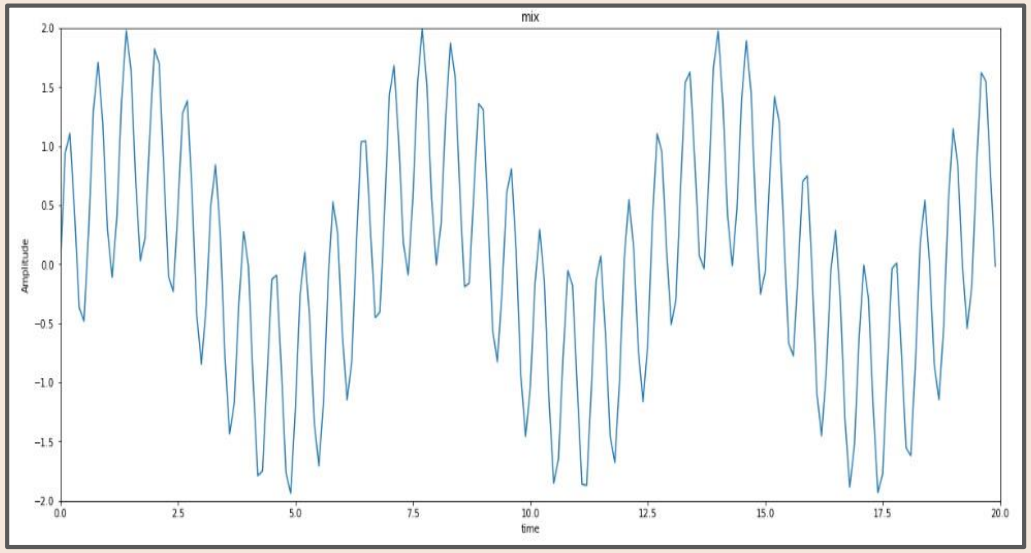

X축: Time(시간)
Y축: Amplitude(진폭)

FFT

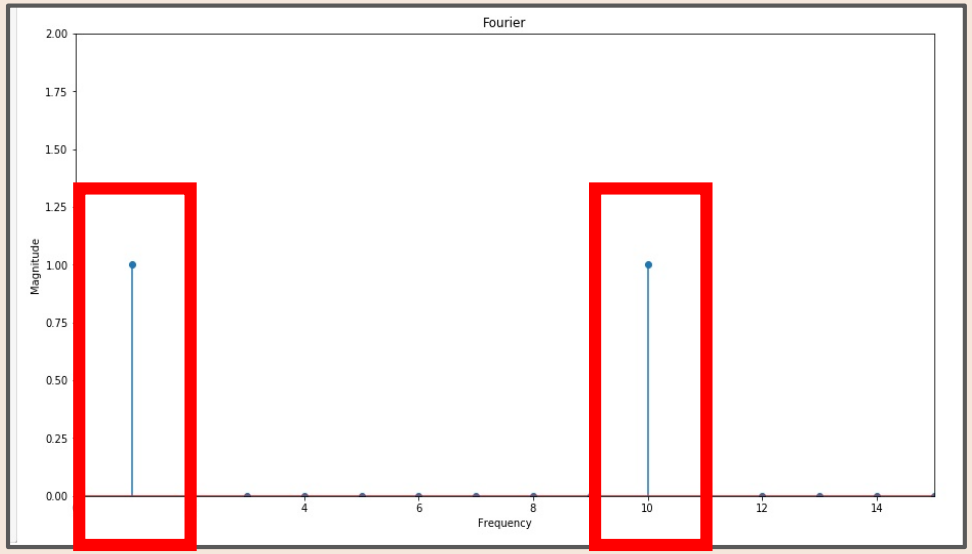

X축: Frequency(주파수)
Y축: Magnitude(주파수의 세기)

04 모델 구조 - Feature Extraction

Q. What is Spectral Envelope?

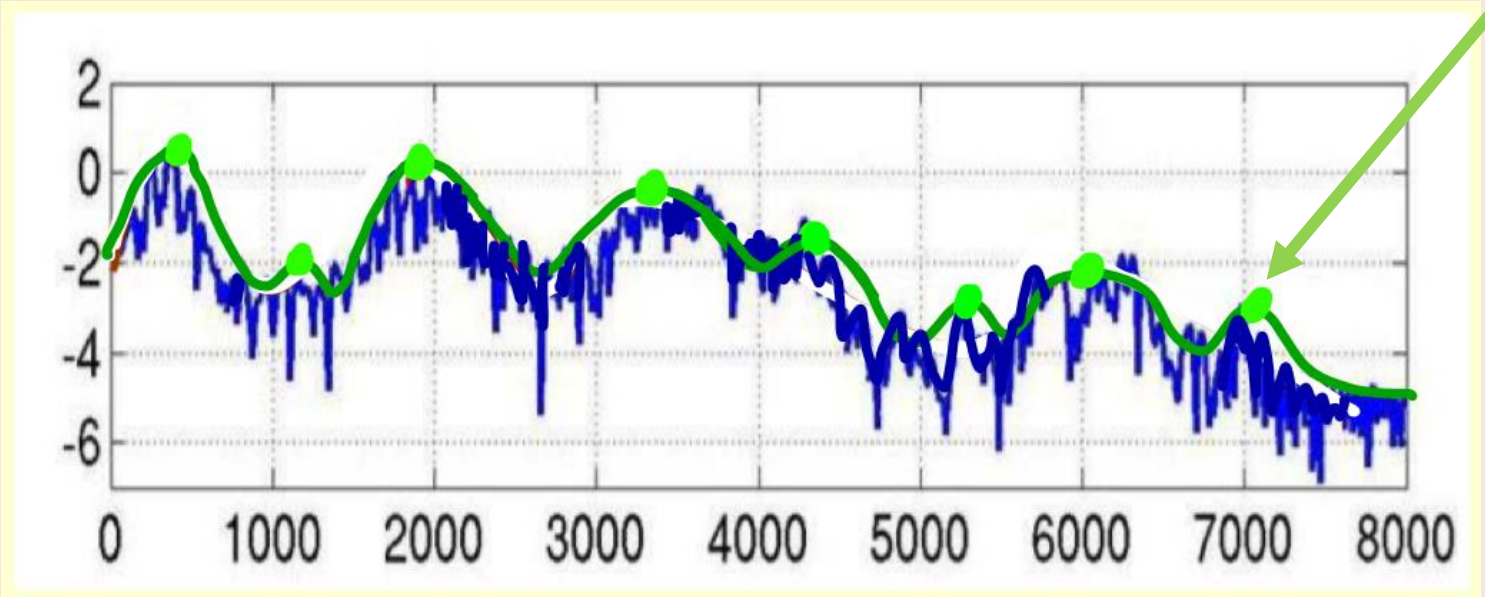

04 모델 구조 - Feature Extraction

Q. What is Spectral Envelope?

● MCEP vs ▲MFCC

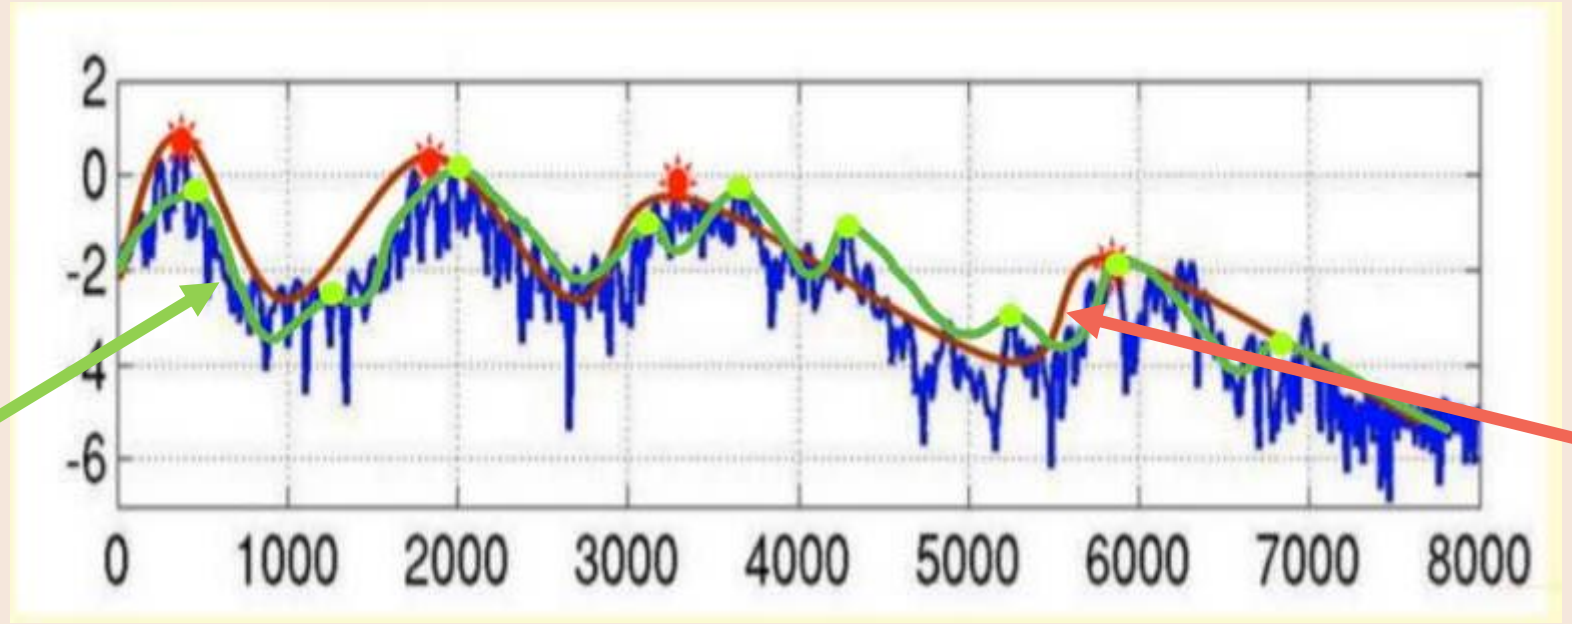

MCEP Spectral Envelope

MFCC Spectral Envelope

04 모델 구조 - Modeling

0. GAN(Generative Adversarial Network) - Background

<pix2pix>

Input

Output

Ground Truth

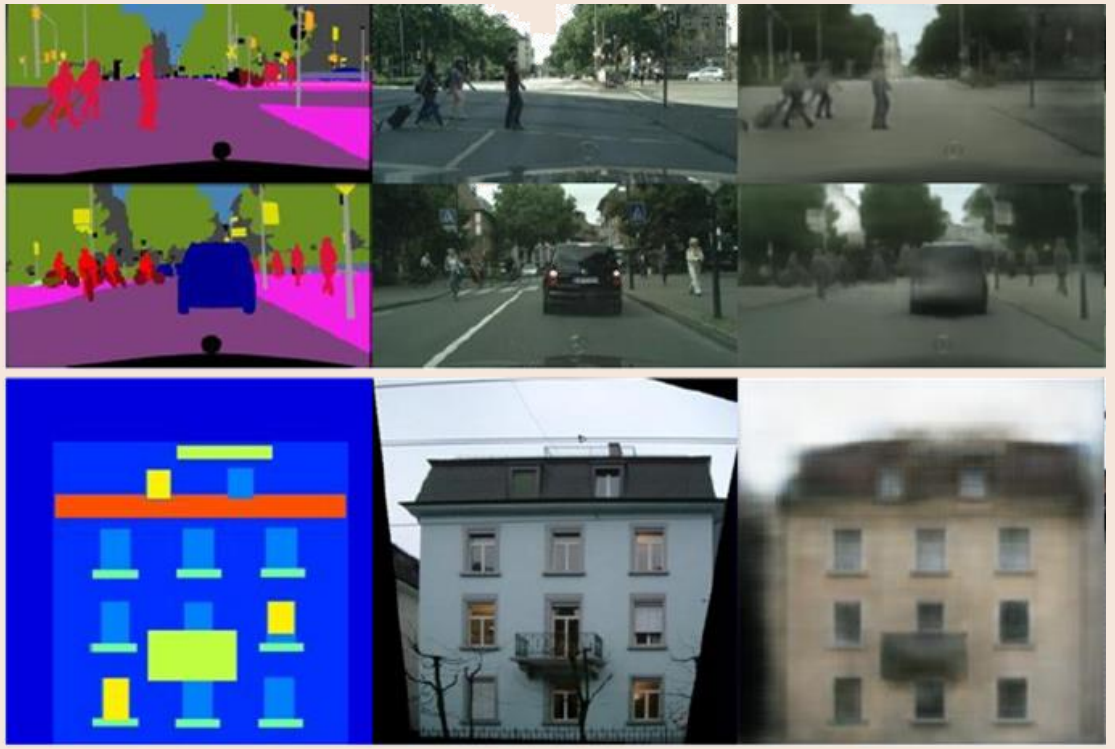

Input Ground Truth L1

04 모델 구조 - Modeling

0. GAN(Generative Adversarial Network)

: Generator와 Discriminator 사이의 경쟁적 학습을 이용한 Network

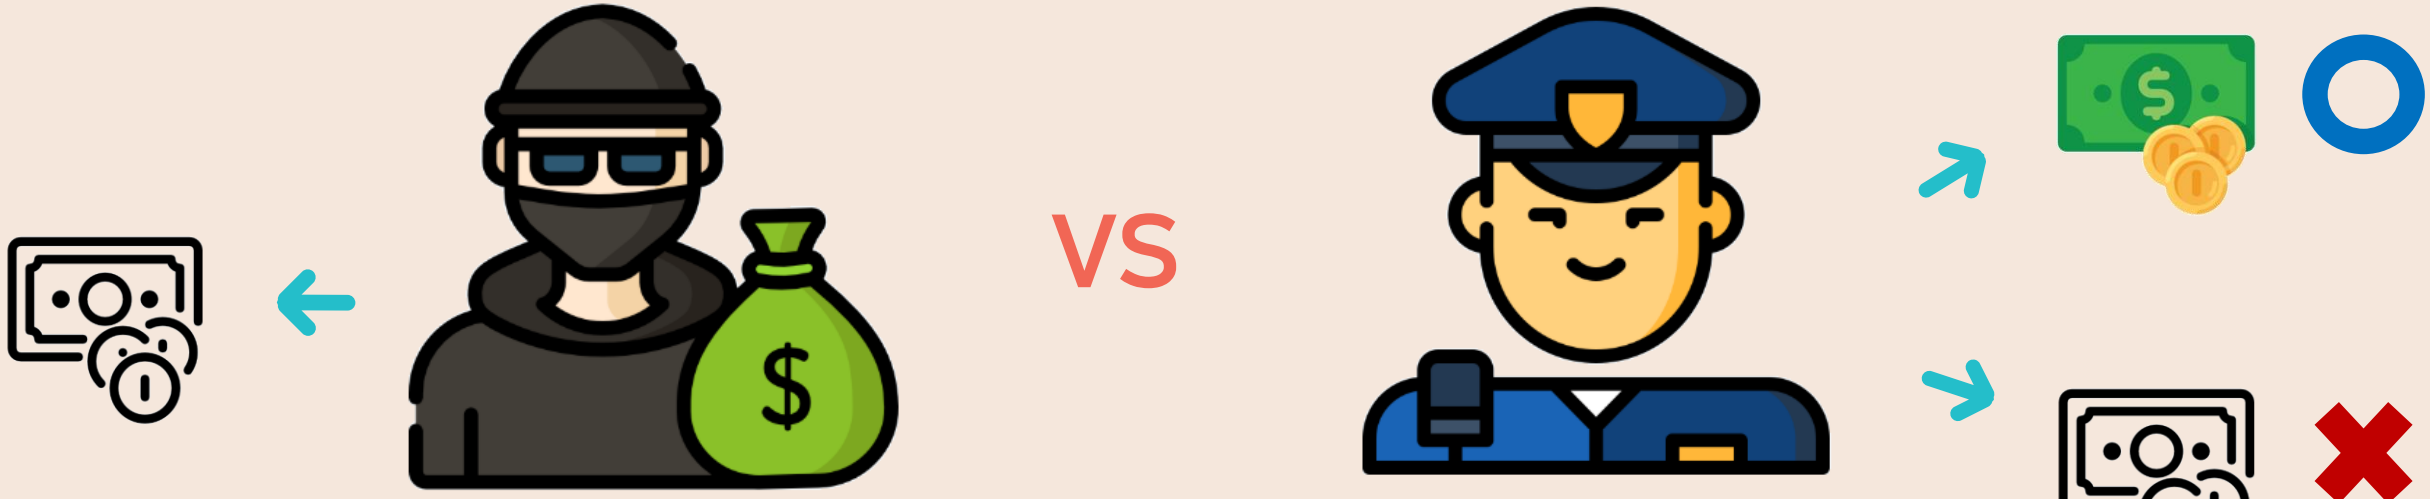

Generator

진짜 지폐와 최대한 비슷한 위조지폐를 만들자!

Discriminator

위조지폐와 진짜 지폐를 잘 구별해내자!

04 모델 구조 - Modeling

0. GAN(Generative Adversarial Network) - Loss Function

: Generator와 Discriminator 사이의 경쟁적 학습을 이용한 Network

[Discriminator]

$$\min_G \max_D V(D,G) = \mathbb{E}_{\boldsymbol{x}\sim p_{\text{data}}(\boldsymbol{x})}[\log D(\boldsymbol{x})] + \mathbb{E}_{\boldsymbol{z}\sim p_{\boldsymbol{z}}(\boldsymbol{z})}[\log(1 - D(G(\boldsymbol{z})))]$$

진짜 데이터 x를 넣었을 때의 값 G가 만든 가짜 데이터 G(z)를 넣었을 때의 값

[Generator]

$$\min_G \max_D V(D,G) = \mathbb{E}_{\boldsymbol{x}\sim p_{\text{data}}(\boldsymbol{x})}[\log D(\boldsymbol{x})] + \mathbb{E}_{\boldsymbol{z}\sim p_{\boldsymbol{z}}(\boldsymbol{z})}[\log(1 - D(G(\boldsymbol{z})))]$$

04 모델 구조 - Modeling

0. GAN(Generative Adversarial Network) - Loss Function

: Generator와 Discriminator 사이의 경쟁적 학습을 이용한 Network

$$\min_{G}\max_{D} V(D,G) = \mathbb{E}_{\boldsymbol{x}\sim p_{\text{data}}(\boldsymbol{x})}[\log D(\boldsymbol{x})] + \mathbb{E}_{\boldsymbol{z}\sim p_{\boldsymbol{z}}(\boldsymbol{z})}[\log(1 - D(G(\boldsymbol{z})))]$$

진짜 데이터 x를 넣었을 때의 값 G가 만든 가짜 데이터 G(z)를 넣었을 때의 값

— : 진짜 데이터를 넣으면 큰 값, 가짜 데이터를 넣으면 작은 값을 출력하도록 Discriminator를 학습시키자!

— : D(G(z))를 극대화하는 G, 즉 Discriminator를 속이는 Generator를 학습시키자!

04 모델 구조 - Modeling

1. CycleGAN(Cycle Generative Adversarial Network)

: 각각 2개의 Generator와 Discriminator를 이용해 전체적인 형태를 유지하면서 스타일만 변형해주는 GAN

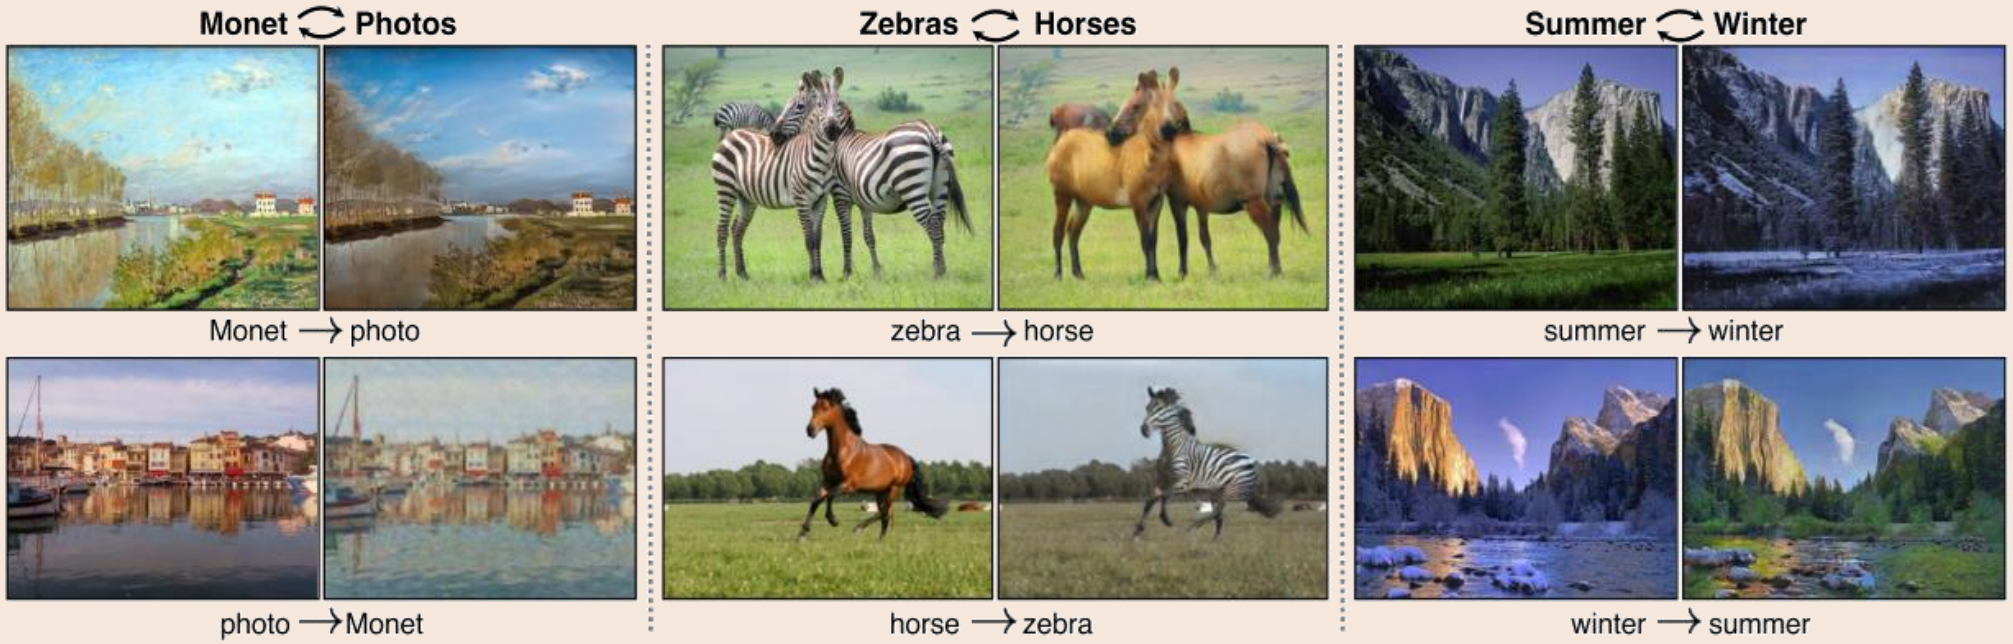

04 모델 구조 - Modeling

1. CycleGAN(Cycle Generative Adversarial Network)

Cycle Consistency

- 서로 2개의 Generator와 Discriminator를 이용해 전체적인 형태를 유지하면서 스타일만 변형해주는 GAN

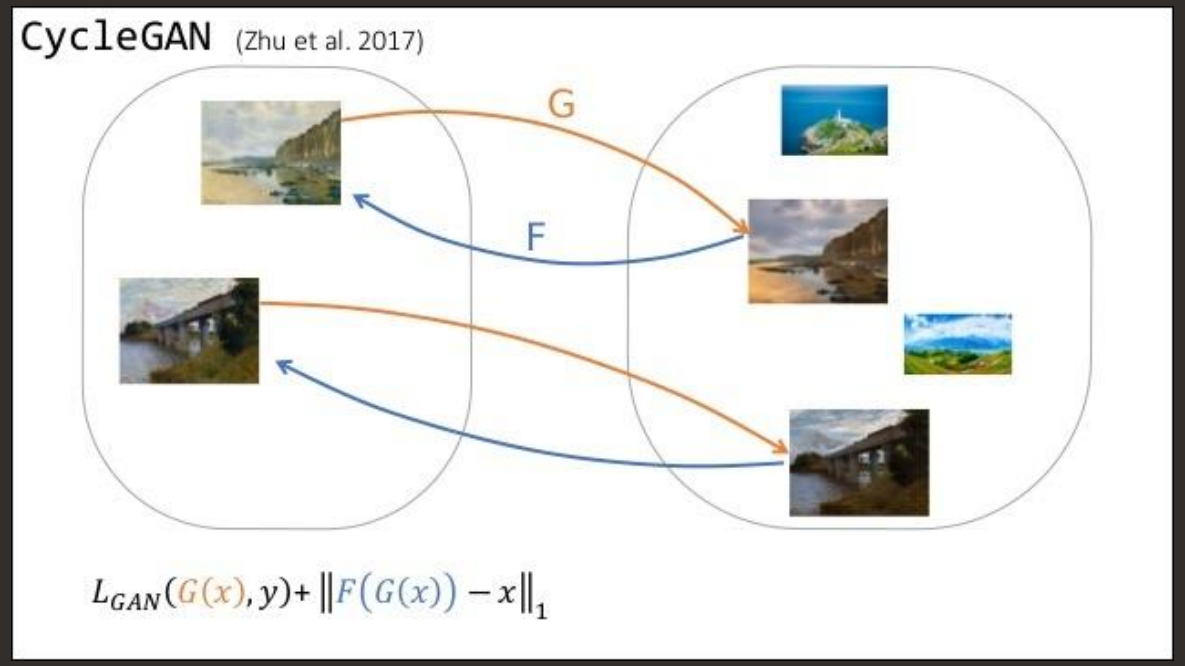

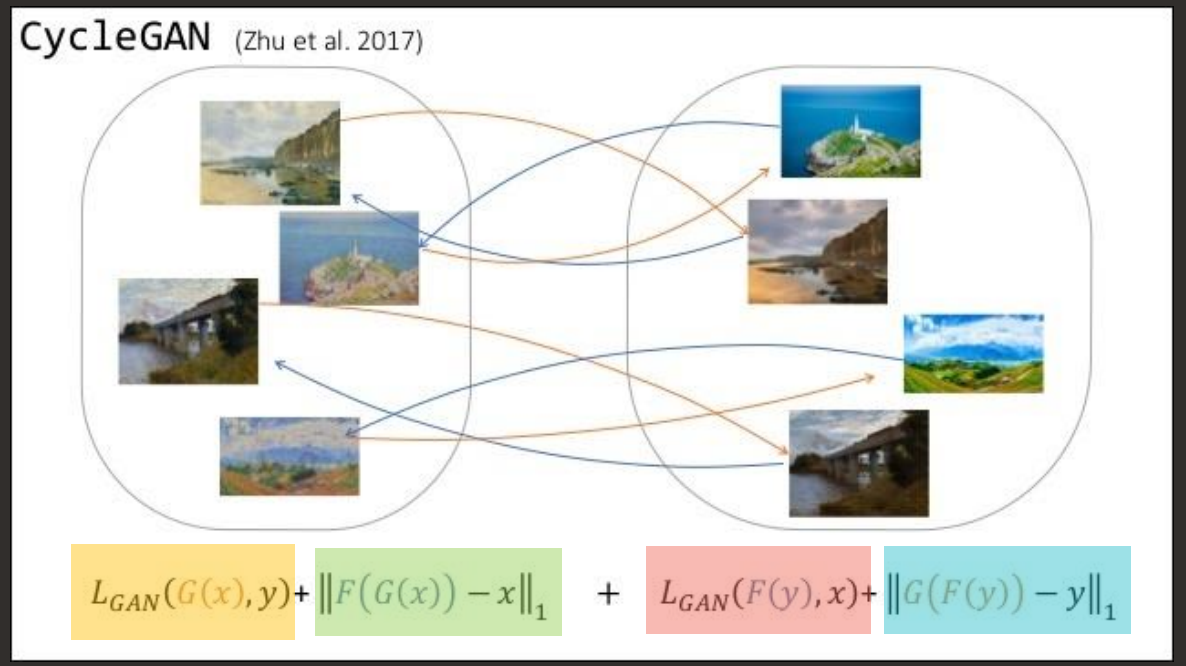

04 모델 구조 - Modeling

1. CycleGAN(Cycle Generative Adversarial Network)

: 각각 2개의 Generator와 Discriminator를 이용해 전체적인 형태를 유지하면서 스타일만 변형해주는 GAN

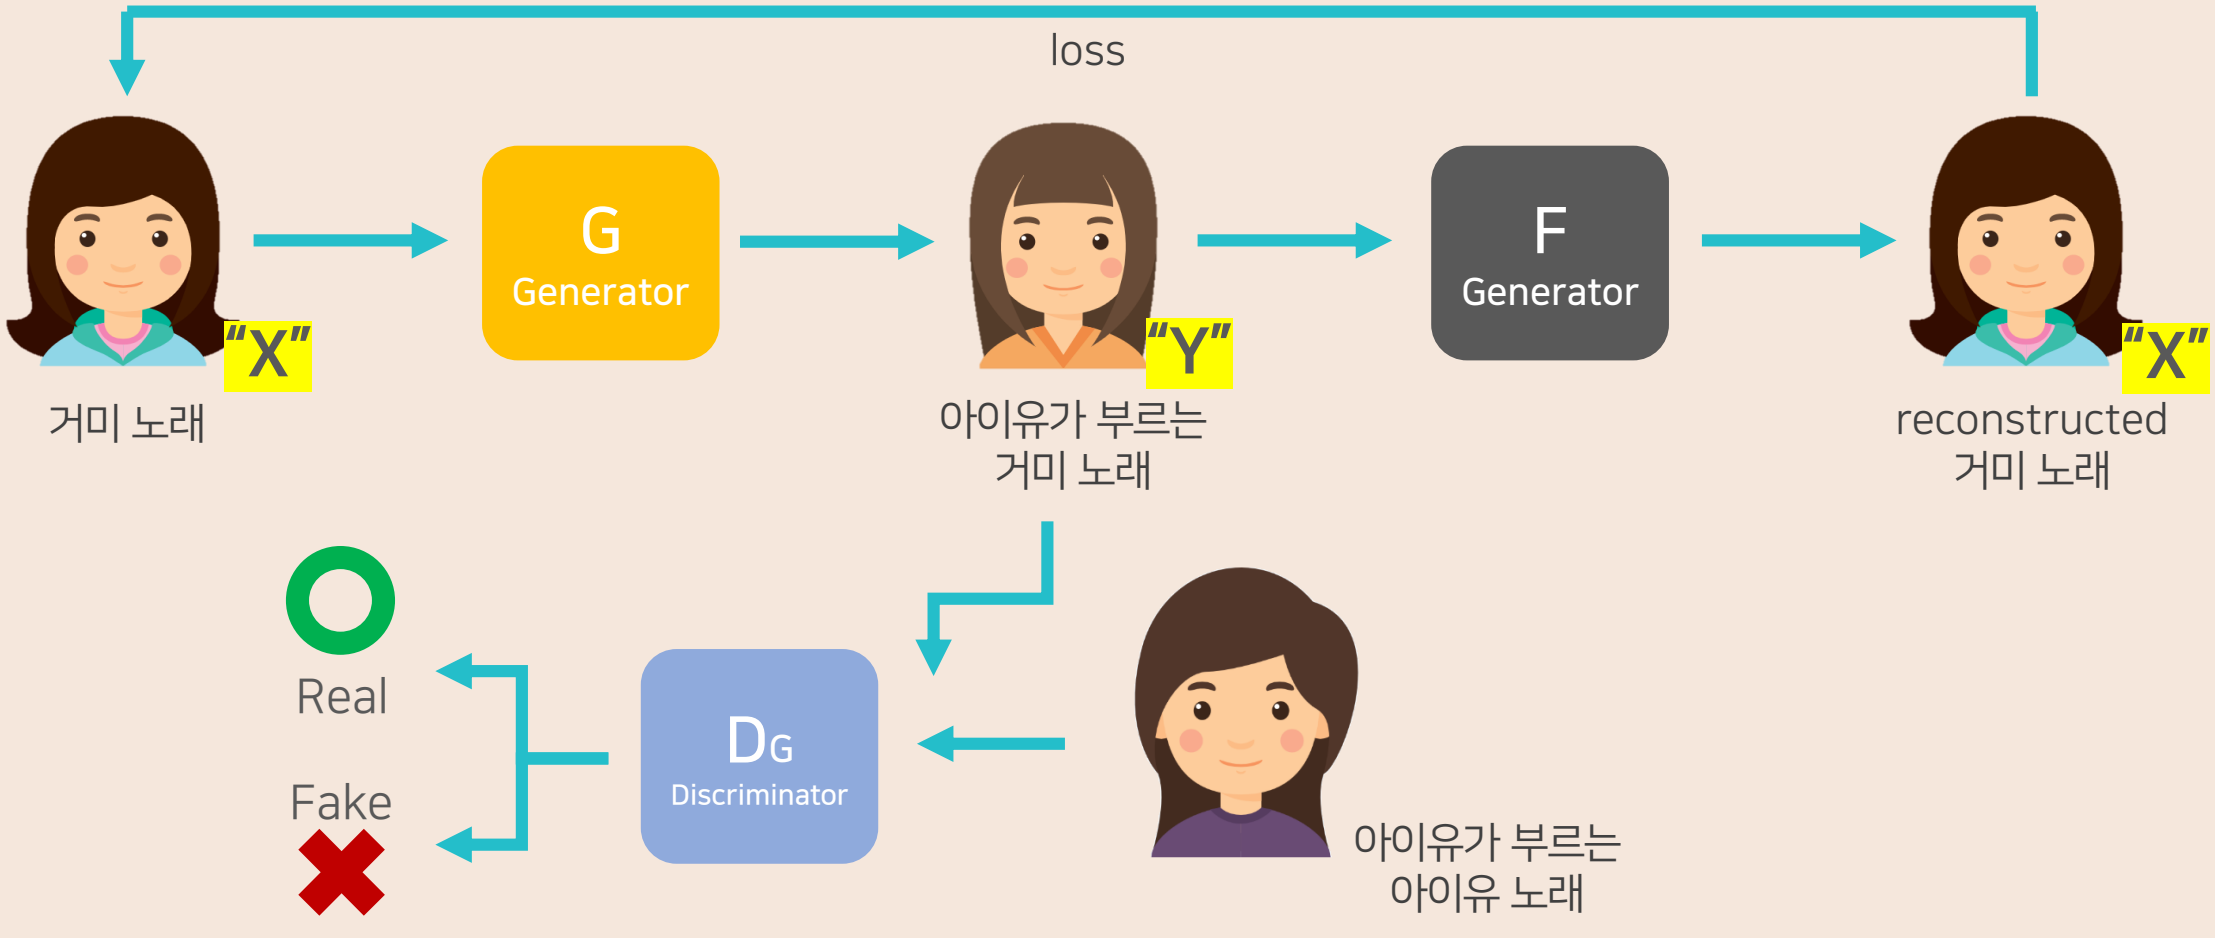

04 모델 구조 - Modeling

1. CycleGAN(Cycle Generative Adversarial Network) - Loss Function

: 각각 2개의 Generator와 Discriminator를 이용해 전체적인 형태를 유지하면서 스타일만 변형해주는 GAN

$$\mathcal{L}_{full} = \mathcal{L}_{adv}(G_{X\to Y}, D_Y) + \mathcal{L}_{adv}(G_{Y\to X}, D_X) + \lambda_{cyc}\mathcal{L}_{cyc}(G_{X\to Y}, G_{Y\to X}) + \mathcal{L}_{id}(G_{X\to Y}, G_{Y\to X})$$

$$\mathcal{L}_{adv}(G_{X\to Y}, D_Y) = \mathbb{E}_{y\sim P_{Data}(y)}\left[\log D_Y(y)\right] + \mathbb{E}_{x\sim P_{Data}(x)}\left[\log(1 - D_Y(G_{X\to Y}(x)))\right]$$

GAN Loss: GAN의 Generator와 Discriminator를 적대적으로 학습하기 위한 Loss이다.
Generator는 X 도메인에서 Y 도메인과 비슷한 데이터를 생성하고,
Discriminator는 진짜 Y도메인 데이터인지 판별하며 학습한다.

04 모델 구조 - Modeling

1. CycleGAN(Cycle Generative Adversarial Network) – Loss Function

: 각각 2개의 Generator와 Discriminator를 이용해 전체적인 형태를 유지하면서 스타일만 변형해주는 GAN

$$\mathcal{L}_{full} = \mathcal{L}_{adv}(G_{X\to Y}, D_Y) + \mathcal{L}_{adv}(G_{Y\to X}, D_X) + \lambda_{cyc}\mathcal{L}_{cyc}(G_{X\to Y}, G_{Y\to X}) + \mathcal{L}_{id}(G_{X\to Y}, G_{Y\to X})$$

$$\mathcal{L}_{cyc}(G_{X\to Y}, G_{Y\to X}) = \mathbb{E}_{x\sim P_{Data}(x)}\left[\|G_{Y\to X}(G_{X\to Y}(x)) - x\|_1\right] + \mathbb{E}_{y\sim P_{Data}(y)}\left[\|G_{X\to Y}(G_{Y\to X}(y)) - y\|_1\right]$$

Cycle Consistency Loss: Generator에 의해 생성된 가짜 데이터를
다시 반대 도메인으로 생성한 데이터와
기존 원본 데이터의 Loss이다.

04 모델 구조 - Modeling

1. CycleGAN(Cycle Generative Adversarial Network) - Loss Function

: 각각 2개의 Generator와 Discriminator를 이용해 전체적인 형태를 유지하면서 스타일만 변형해주는 GAN

$$\mathcal{L}_{full} = \mathcal{L}_{adv}(G_{X\to Y}, D_Y) + \mathcal{L}_{adv}(G_{Y\to X}, D_X) + \lambda_{cyc}\mathcal{L}_{cyc}(G_{X\to Y}, G_{Y\to X}) + \mathcal{L}_{id}(G_{X\to Y}, G_{Y\to X})$$

$$\mathcal{L}_{id}(G_{X\to Y}, G_{Y\to X}) = \mathbb{E}_{y\sim P_{Data}(y)}[\|G_{X\to Y}(y) - y\|_1] + \mathbb{E}_{x\sim P_{Data}(x)}[\|G_{Y\to X}(x) - x\|_1]$$

Identity Loss: 진짜 Y 도메인의 데이터가 Y 도메인 Discriminator에 들어왔을 때의 Mapping Function.
이 과정에서 Y 도메인의 특징을 유지하도록 만들어
X 도메인의 형태를 깊게 학습할 수 있도록 한다!

04 모델 구조 - Modeling

2. CycleGAN + BEGAN(Boundary Equilibrium Generative Adversarial Network)

: CycleGAN과 동일한 구조에서 D가 AutoEncoder를 가지며 Equilibrium을 통해 G와 D의 평형을 유지하는 GAN

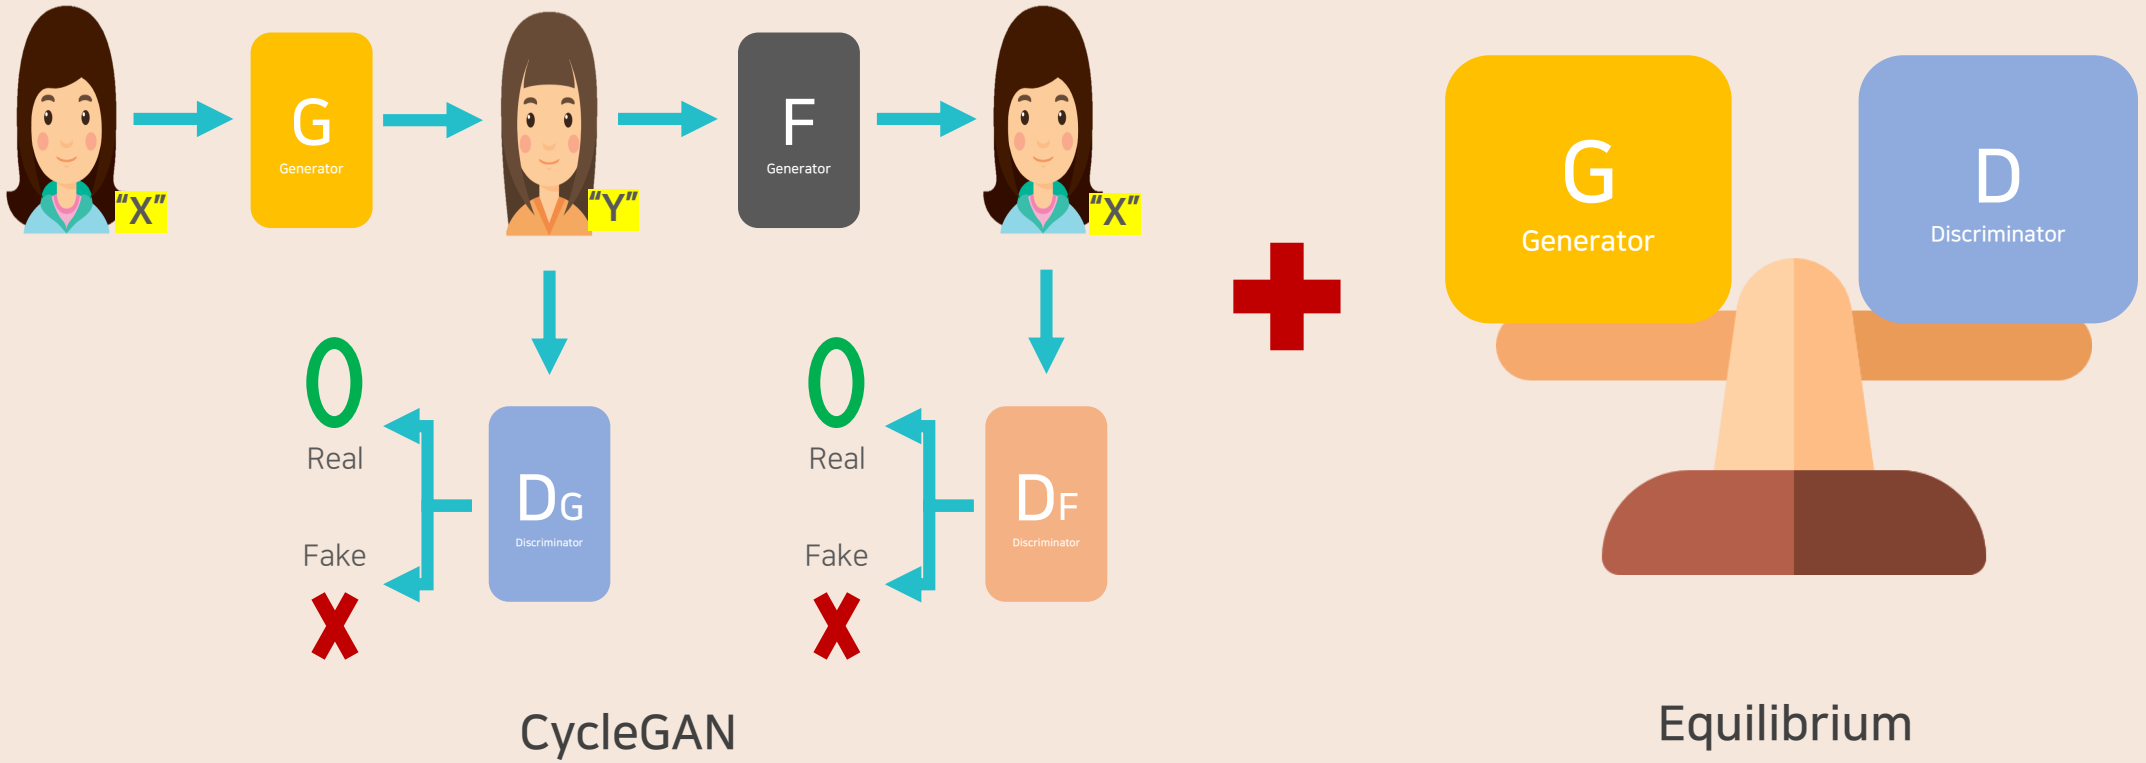

04 모델 구조 - Modeling

2. CycleGAN + BEGAN(Boundary Equilibrium Generative Adversarial Network)

: CycleGAN과 동일한 구조에서 D가 AutoEncoder를 가지며 Equilibrium을 통해 D와 G의 평형을 유지하는 GAN

WHY BEGAN?

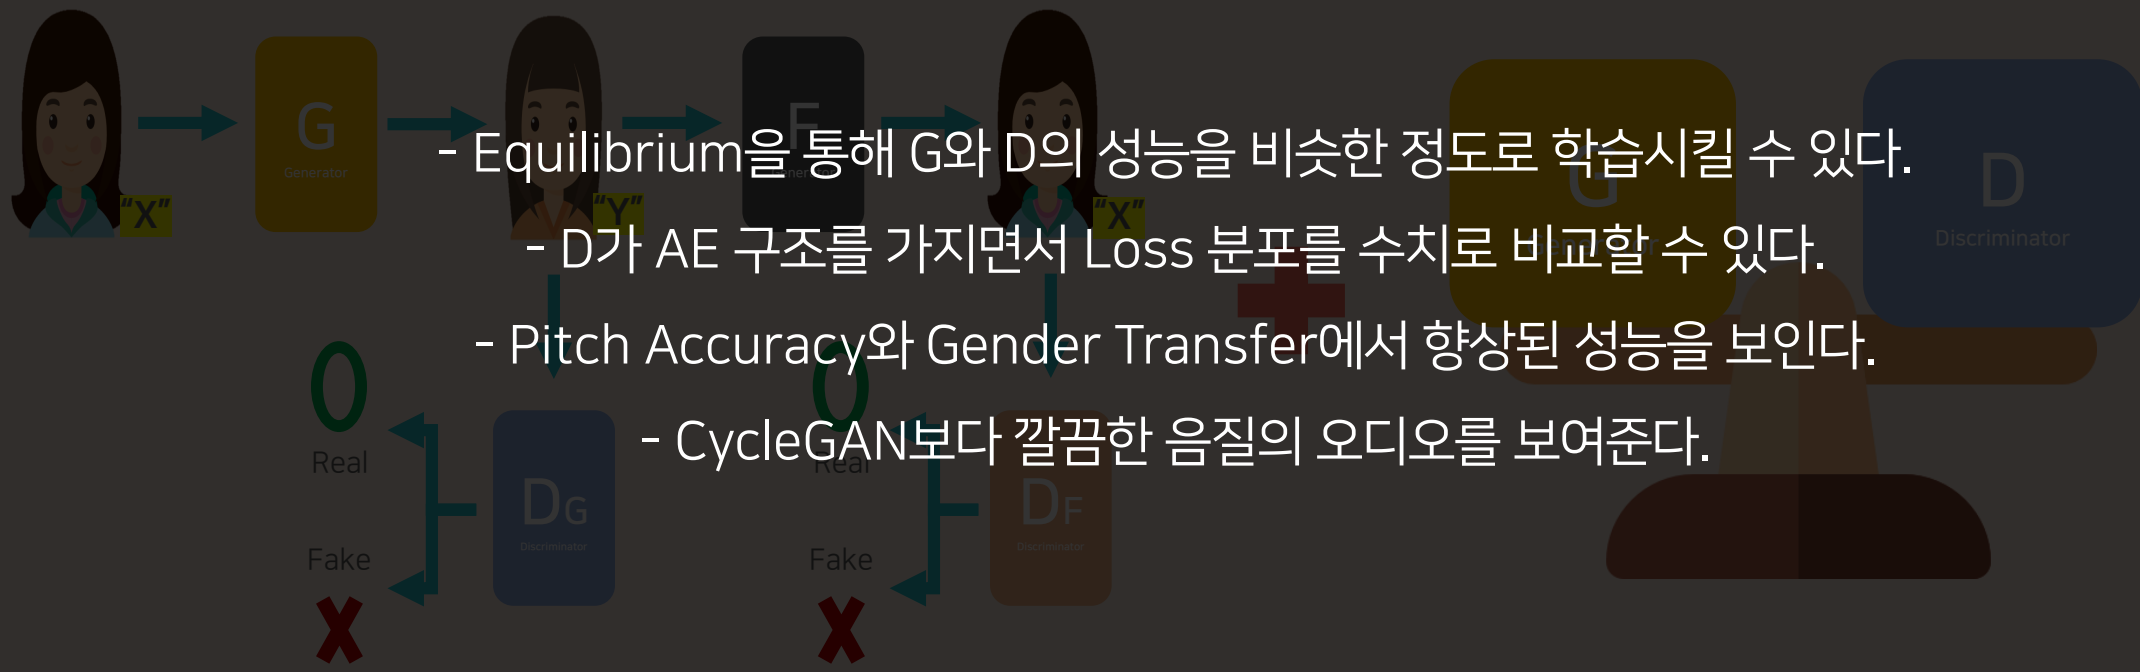

- Equilibrium을 통해 G와 D의 성능을 비슷한 정도로 학습시킬 수 있다.
- D가 AE 구조를 가지면서 Loss 분포를 수치로 비교할 수 있다.
- Pitch Accuracy와 Gender Transfer에서 향상된 성능을 보인다.
- CycleGAN보다 깔끔한 음질의 오디오를 보여준다.

04 모델 구조 - Modeling

3. Full Architecture

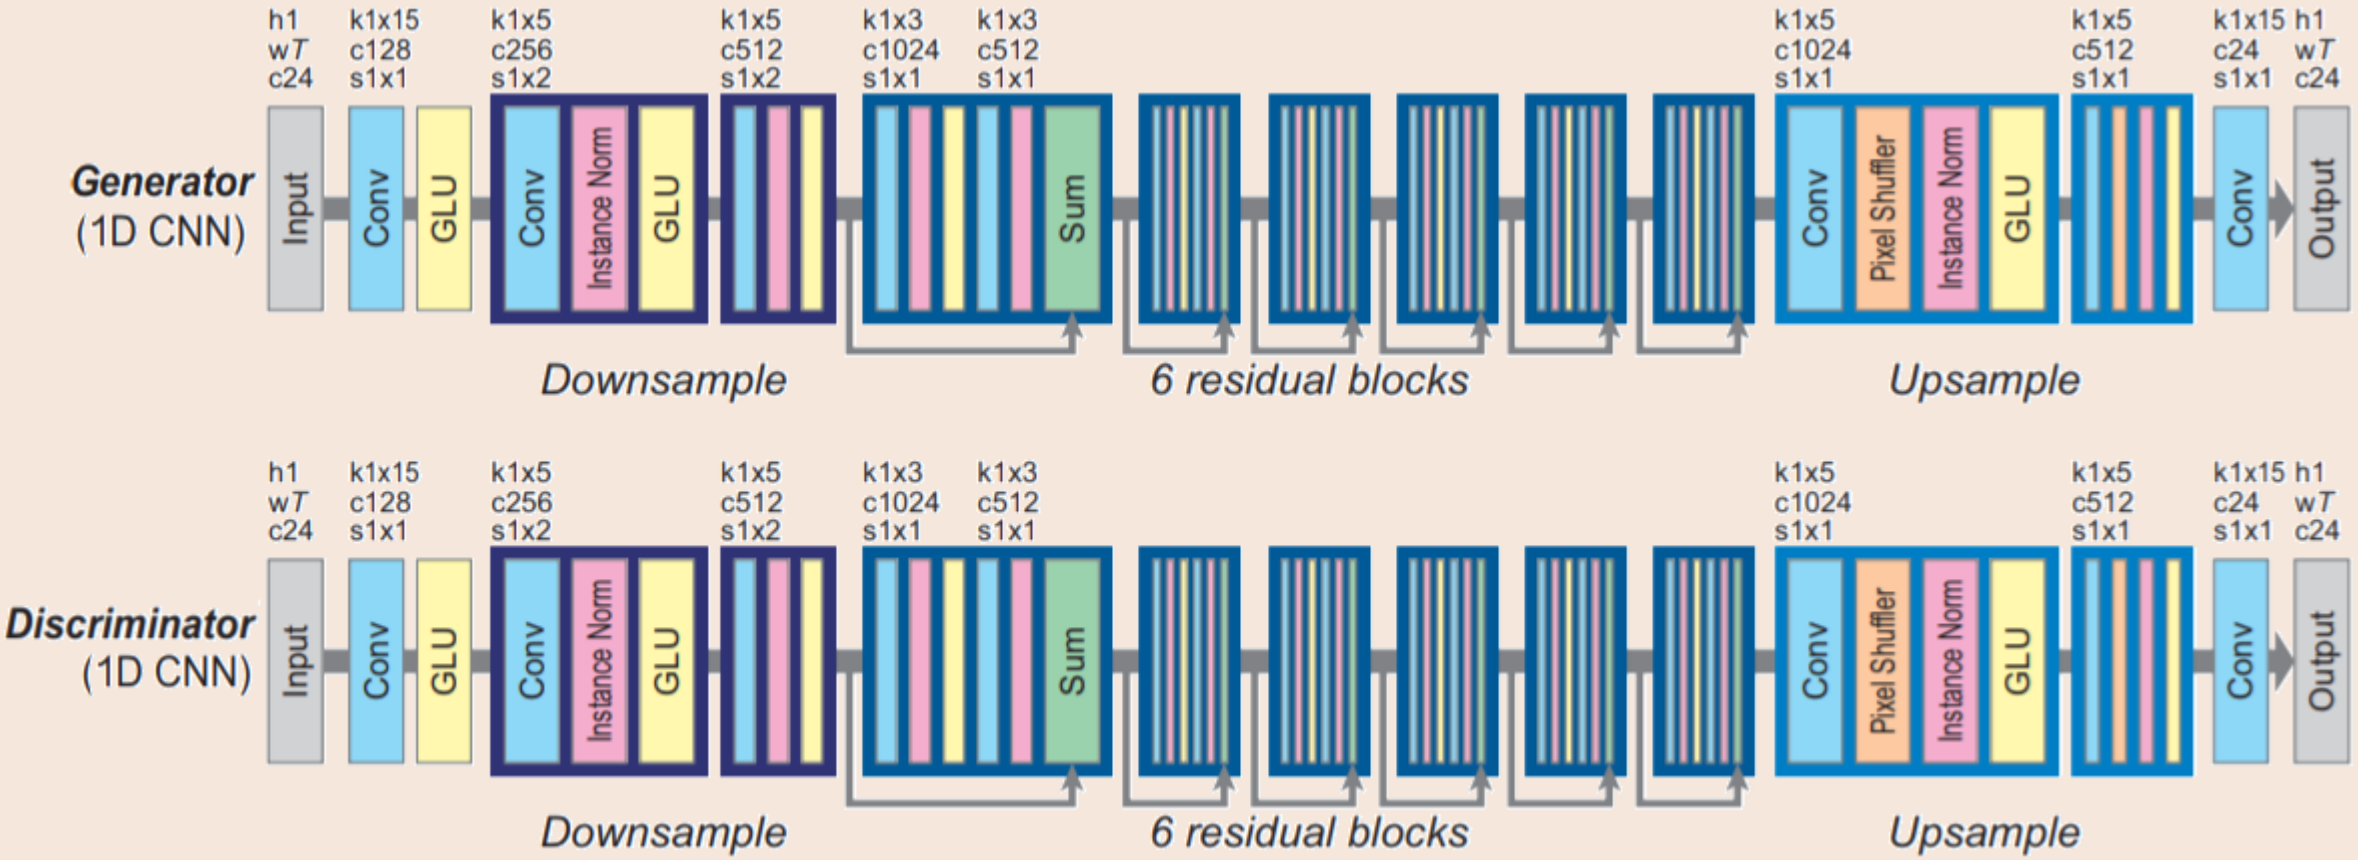

05. Conclusion

Final Result & Discussion

05 결론

1. 결과 시연 : 거미 - You are My Everything(아이유 Ver.)

05 결론

1. 결과 시연 : 케이윌 – 내 생에 아름다운(10cm Ver.)

05 결론

2. 한계점

apple → orange

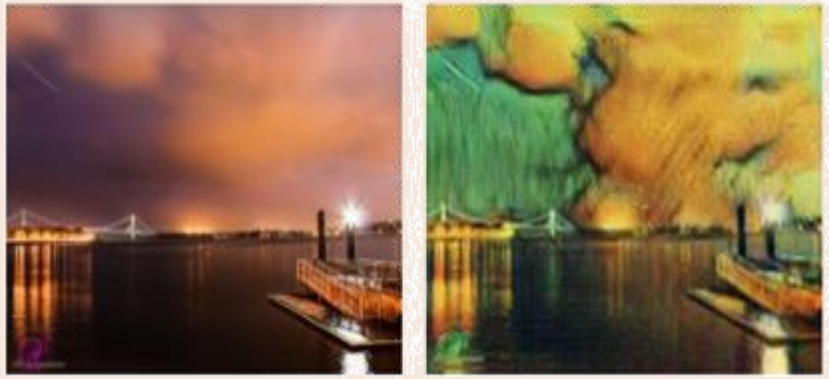

photo → Van Gogh

Singing Style(창법) Conversion은 불가능, Singing Voice Conversion만 가능 ☹

05 결론

2. 한계점

Hyper-parameter Tuning ☹

~~n_frames~~

~~frame_period~~

~~epoch~~

~~cycle_gamma~~

데이터 변경 & 하이퍼 파라미터 튜닝을 시도했지만

가시적인 변화는 보지 못 함

05 결론

3. 개선 방향

- WaveNet AutoEncoder를 적용한 시도

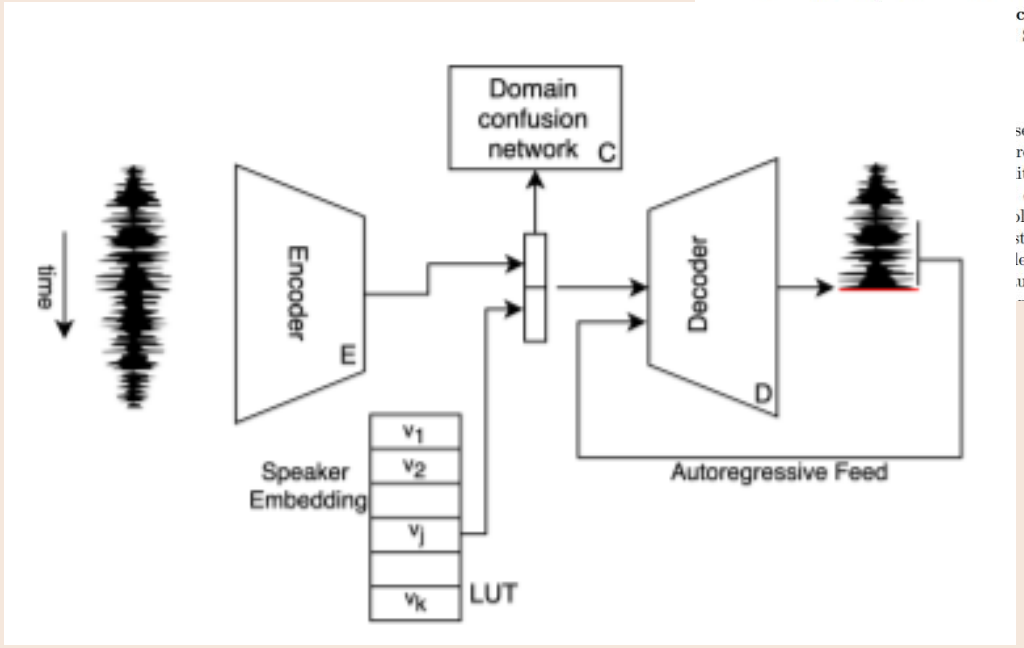

Neural Audio Synthesis of Musical Notes with WaveNet Autoencoders

ck* [1] Adam Roberts [1] Sander Dieleman [2] Douglas Eck [1]
Simonyan [2] Mohammad Norouzi [1]

perhaps because of them, synthesizers have had a profound effect on the course of music and culture in the past half century (Punk, 2014).

In this paper, we outline a data-driven approach to audio synthesis. Rather than specifying a specific arrangement of oscillators or an algorithm for sample playback, such as in FM Synthesis or Granular Synthesis (Chowning, 1973; Xenakis, 1971), we show that it is possible to generate new types of expressive and real-

06 팀원 소개

김유민
투빅스 11기
서울시립대학교
영어영문학과
16학번

이소라
투빅스 11기
덕성여자대학교
정보통계학과
15학번

정혜인
투빅스 11기
숙명여자대학교
컴퓨터과학전공
17학번

박진혁
투빅스 12기
성균관대학교
전기전자공학부
15학번

조민호
투빅스 12기
서강대학교
철학과
14학번

최승호
투빅스 12기
국민대학교
소프트웨어학부
14학번

감사합니다 ☺

김유민 박진혁 이소라 정혜인 조민호 최승호